

Laporan Praktikum 4 Kontrol Cerdas

Nama : Ahimsa Raihan Alwikan Abhipraya

NIM : 224308002

Kelas : TKA 6A

Akun Github (Tautan) : <https://github.com/ahimsarai>

Student Lab Assistant : Muhammad Fatih Anfa Adhima

1. Judul Percobaan

Reinforcement Learning for Autonomous Control

2. Tujuan Percobaan

Tujuan percobaan dalam praktikum ini adalah sebagai berikut:

- Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
- Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
- Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
- Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
- Menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori



- a. Dalam konteks autonomous control, RL memungkinkan sistem untuk belajar mengendalikan suatu proses tanpa perlu pemrograman eksplisit. Agen berusaha untuk memaksimalkan reward kumulatif dengan mengembangkan strategi optimal berdasarkan pengalaman yang dikumpulkan. Beberapa algoritma yang umum digunakan meliputi Q-Learning, Deep Q-Networks (DQN), dan Proximal Policy Optimization (PPO). Q-Learning adalah metode berbasis tabel yang memperbarui nilai Q untuk menemukan kebijakan optimal, sedangkan DQN menggunakan jaringan saraf tiruan untuk menangani lingkungan dengan state yang kompleks. Sementara itu, PPO adalah pendekatan yang lebih stabil dan sering digunakan dalam aplikasi kontrol robotik.
- b. Penerapan RL dalam autonomous control mencakup berbagai bidang seperti pengendalian robot, kendaraan otonom, dan optimasi sistem industri. Dalam robotika, RL digunakan untuk mengajarkan robot berjalan, menavigasi, atau melakukan tugas tertentu secara mandiri. Dalam kendaraan otonom, RL membantu dalam pengambilan keputusan untuk navigasi yang lebih aman dan efisien. Di sektor industri, RL dapat digunakan untuk meningkatkan efisiensi produksi dengan menyesuaikan kontrol sistem berdasarkan perubahan lingkungan.

4. Analisis dan Diskusi

Pada praktikum tentang Reinforcement Learning (RL) untuk autonomous control, eksperimen menunjukkan bahwa pendekatan ini memungkinkan agen untuk belajar mengambil keputusan optimal melalui interaksi dengan lingkungan. Dengan menerapkan algoritma seperti Q-Learning, Deep Q-Networks (DQN), atau Proximal Policy Optimization (PPO), agen dapat menyesuaikan kebijakan berdasarkan reward yang diperoleh, sehingga meningkatkan kinerja dalam mengendalikan sistem secara otomatis. Proses pembelajaran RL bergantung pada keseimbangan

antara eksplorasi dan eksploitasi, di mana agen harus mencoba berbagai tindakan sebelum menemukan strategi terbaik. Tantangan utama dalam praktikum ini mencakup masalah **sparse reward**, yang dapat memperlambat pembelajaran, serta kebutuhan akan tuning parameter seperti learning rate dan discount factor agar model bekerja secara optimal. Hasil praktikum menunjukkan bahwa RL dapat meningkatkan efisiensi autonomous control, tetapi keberhasilannya sangat bergantung pada kualitas algoritma yang digunakan, optimasi parameter, dan kemampuan agen dalam beradaptasi dengan lingkungan yang dinamis.

5. Data dan Output Hasil Pengamatan

No	Variabel	Hasil Pengamatan
1	Cartpole.py	 <pre> 40 for state, action, reward, next_state, done in minibatch: 41 target = reward 42 if not done: </pre> PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS COMMENTS Episode: 28/50, Score: 25, Epsilon: 0.88 Episode: 29/50, Score: 18, Epsilon: 0.87 Episode: 30/50, Score: 27, Epsilon: 0.87 Episode: 31/50, Score: 23, Epsilon: 0.86 Episode: 32/50, Score: 18, Epsilon: 0.86 Episode: 33/50, Score: 11, Epsilon: 0.86 Episode: 34/50, Score: 26, Epsilon: 0.85 Episode: 35/50, Score: 31, Epsilon: 0.85 Episode: 36/50, Score: 13, Epsilon: 0.84 Episode: 37/50, Score: 18, Epsilon: 0.84 Episode: 38/50, Score: 52, Epsilon: 0.83 Episode: 39/50, Score: 19, Epsilon: 0.83 Episode: 40/50, Score: 42, Epsilon: 0.83 Episode: 41/50, Score: 58, Epsilon: 0.82 Episode: 42/50, Score: 12, Epsilon: 0.82 Episode: 43/50, Score: 15, Epsilon: 0.81 Episode: 44/50, Score: 19, Epsilon: 0.81 Episode: 45/50, Score: 19, Epsilon: 0.81 Episode: 46/50, Score: 16, Epsilon: 0.80 Episode: 47/50, Score: 11, Epsilon: 0.80 Episode: 48/50, Score: 31, Epsilon: 0.79 Episode: 49/50, Score: 14, Epsilon: 0.79 Episode: 50/50, Score: 32, Epsilon: 0.79 PS C:\Users\User\Intelligent-control-week4> & C:/Users/User/AppData/Local/Programs
2	Mountainair.py	 <pre> 14 self.gamma = 0.99 # Discount fac 15 </pre> PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL POR Episode: 59/80, Score: 199, Epsilon: 0.75 Episode: 60/80, Score: 199, Epsilon: 0.74 Episode: 61/80, Score: 199, Epsilon: 0.74 Target Network updated! Episode: 62/80, Score: 199, Epsilon: 0.74 Episode: 63/80, Score: 199, Epsilon: 0.73 Episode: 64/80, Score: 199, Epsilon: 0.73 Episode: 65/80, Score: 199, Epsilon: 0.73 Episode: 66/80, Score: 199, Epsilon: 0.72 Episode: 67/80, Score: 199, Epsilon: 0.72 Episode: 68/80, Score: 199, Epsilon: 0.71 Episode: 69/80, Score: 199, Epsilon: 0.71 Episode: 70/80, Score: 199, Epsilon: 0.71 Episode: 71/80, Score: 199, Epsilon: 0.70 Target Network updated! Episode: 72/80, Score: 199, Epsilon: 0.70 Episode: 73/80, Score: 199, Epsilon: 0.70 Episode: 74/80, Score: 199, Epsilon: 0.69 Episode: 75/80, Score: 199, Epsilon: 0.69 Episode: 76/80, Score: 199, Epsilon: 0.69 Episode: 77/80, Score: 199, Epsilon: 0.68 Episode: 78/80, Score: 199, Epsilon: 0.68 Episode: 79/80, Score: 199, Epsilon: 0.68 Episode: 80/80, Score: 199, Epsilon: 0.67 PS C:\Users\User\Intelligent-control-week4_assign

6. Kesimpulan

1. Dari percobaan yang telah dilakukan, dapat disimpulkan bahwa:
2. Percobaan ini memanfaatkan Reinforcement Learning untuk melatih agen dalam menyelesaikan tugas pada lingkungan CartPole dan MountainCar menggunakan algoritma seperti Q-Learning dan Deep Q-Networks (DQN).
3. Hasil percobaan menunjukkan bahwa pada lingkungan CartPole, agen mampu menyeimbangkan tiang lebih lama setelah beberapa episode pelatihan, sedangkan pada MountainCar, agen berhasil mencapai puncak bukit dengan strategi yang lebih optimal setelah eksplorasi yang cukup.
4. Tantangan utama dalam percobaan ini meliputi pemilihan parameter yang tepat, seperti learning rate dan discount factor, agar agen dapat belajar secara efisien dan tidak terjebak dalam solusi suboptimal.
5. Hasil akhir menunjukkan bahwa dengan tuning parameter yang sesuai dan jumlah episode pelatihan yang cukup, Reinforcement Learning dapat digunakan secara efektif untuk menyelesaikan berbagai tugas autonomous control dalam lingkungan simulasi.

7. Saran

Gunakan berbagai algoritma Reinforcement Learning seperti Q-Learning, Deep Q-Networks (DQN), atau Proximal Policy Optimization (PPO) untuk membandingkan efektivitas masing-masing dalam menyelesaikan tugas pada lingkungan CartPole dan MountainCar. Lakukan tuning parameter secara sistematis, termasuk learning rate, discount factor, dan epsilon decay, untuk memastikan agen dapat belajar secara optimal tanpa mengalami overfitting atau stagnasi dalam eksplorasi. Selain itu, visualisasikan proses pelatihan dengan grafik reward kumulatif serta analisis kinerja agen pada setiap episode untuk memahami pola pembelajaran yang terjadi. Uji model dengan kondisi awal yang berbeda untuk mengevaluasi seberapa baik agen dapat beradaptasi dalam berbagai skenario. Dokumentasikan setiap langkah dengan jelas agar mahasiswa dapat mereplikasi eksperimen dengan mudah dan memahami konsep dasar Reinforcement Learning secara lebih mendalam.

8. Daftar Pustaka

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.